

Nonlinearity를 갖는 CSTR 공정에서의 RL 제어 구현 및 보상함수 변경을 통한 성능 개선

Seunghyun Cho, Hain Lee, Jaehyun Oh

April 29, 2025

1 Backgrounds

1.1 CSTR

Continuous Stirred Tank Reactor (CSTR)은 연속적으로 유체를 주입하고 동시에 반응과 혼합이 일어나는 대표적인 화학 반응기이다. 주어진 체적 내에서 반응물이 완전히 혼합된다고 가정하며, 반응 속도, 농도 변화, 온도 제어 등 동적 특성이 중요한 시스템이다. 특히, 비선형성(Nonlinearity)으로 인해 작은 입력 변화에도 시스템 거동이 크게 달라질 수 있어 정밀한 제어 전략이 요구된다.

1.2 Process Control

Process Control은 산업 공정의 안정적 운전과 최적 성능 유지를 목표로 하는 제어 공학 분야이다. 화학, 석유화학, 제약 등의 산업에서 반응기, 증류탑, 열교환기 등 다양한 장비들의 변수(온도, 압력, 유량 등)를 제어하기 위해 활용된다. 비선형성과 시간 지연 등 복잡한 공정 특성 때문에 전통적인 PID 제어를 넘어, 모델 예측 제어(Model Predictive Control)나 강화학습 기반 제어 방법이 연구되고 있다.

2 Project Summary

Process Control의 실패는 안전성 문제로 직결될 수 있다. CSTR 공정은 Nonlinearity 특성을 지니므로써 제어의 어려움을 유발하므로, 보다 유연하고 적응적인 제어 전략이 요구된다.

본 프로젝트는 Nonlinearity 특성을 지닌 CSTR 공정에 대하여 강화학습(Reinforcement Learning, RL) 기반 제어 기법을 적용하고, 이를 통해 기존 제어 방법의 한계를 극복하고자 한다. 이에 따라 본 연구에서는 심층 강화학습 알고리즘인 Deep Q-Network (DQN), Proximal Policy Optimization (PPO), Deep Deterministic Policy Gradient (DDPG) 등을 적용하여 공정의 동적 제어를 수행하고, CSTR 공정의 벤치마크인 Van de Vusse 반응을 통해 Reward 함수 설계에 따른 제어 성능 변화 및 공정 안정성 확보 가능성을 검증하고자 한다.

3 Related Works

3.1 Library

Bloor et al.은 Process Control의 표준 환경을 제시함으로써, Process Control 분야의 Reinforcement Learning (RL) 연구의 접근성을 높인 바 있다.[1]

3.2 Previous Researchs

Park et al.은 CSTR의 비선형성을 고려한 보상 함수 최적화로 MPC 대비 성능을 12% 향상시킨 바 있으며[2], Yu et al.는 PPO 기반 제어 프레임워크를 통해 외란에도 불구하고 CSTR의 안정적 제어에 성공하였다.[3] Bloor et al.은 강화 학습과 비선형 MPC의 성능 비교를 위한 표준 환경을 제시했고[4], Chen et al. (1995)은 CSTR 비선형 제어 문제의 초기 벤치마크를 제공하며 후속 연구의 기반을 마련했다.[5] 또한 Park et al.은 Process Control에서의 RL의 활용 연구 동향을 총망라하여, CSTR의 복잡한 동역학 제어에 유효함을 확인하였다.[6]

4 Project Milestones

1. PC-Gym 라이브러리의 반응식을 수정하여, Van de Vusse 반응을 묘사하고, [3] 에서 활용된 Tank Level을 고려대상으로 추가하여, 해당 상황에 맞는 State 와 Action을 재정의한다.

Table 4. State and action values of the CSTR.

	Symbol	Description	Initial value	Minimum	Maximum	Units
States	C_A	Concentration of substance A	2.14	0	3.5	g/L
	C_B	Concentration of substance B	1.09	0	1.8	g/L
	T	Temperature in the reactor	114.2	80	140	°C
	T_c	Temperature in the cooling jacket	112.9	90	135	°C
Actions	\dot{V}/V_R	Feed flow	14.19	3	35	h^{-1}
	\dot{Q}_C	Heat removal	-1113.5	-9000	0	kJ/h

Figure 1: Defined states and actions in previous research

2. DQN, PPO 및 DDPG를 활용하여, 각 알고리즘에 따른 베이스 모델을 구현한다.
3. Reward 함수를 조절하며, 세 알고리즘의 베이스모델에 대하여 벤치마크 성능을 높일 수 있는 방법을 탐색하고 이유를 공학적으로 접근하여 탐색한다.

References

- [1] MaximilianB2, “pc-gym: Process control environments for reinforcement learning,” <https://github.com/MaximilianB2/pc-gym/tree/main>, accessed: 2025-04-29.
- [2] 박준수, “강화학습 기반 화학 공정 제어 성능 향상을 위한 보상 함수 시뮬레이션 연구,” *제어 로봇 시스템학회 논문지*, 2024.
- [3] M. Yu, B. Li, S. Zhao, N. Roy, and B. Zhang, “Ppo-based resilient control framework for safer operation of exothermic cstr,” *Process Safety and Environmental Protection*, vol. 193, pp. 558–576, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957582024014721>
- [4] M. Bloor, J. Torracca, and C. Tsay, “Pc-gym: Benchmark environments for process control problems,” *arXiv preprint arXiv:2410.22093*, 2024. [Online]. Available: <https://arxiv.org/abs/2410.22093>
- [5] H. Chen, H. Kremling, and F. Allgöwer, “Nonlinear predictive control of a benchmark cstr,” *Proceedings of the 3rd European Control Conference, Rome-Italy.*, pp. 3247–3252, 01 1995.
- [6] J. Park, H. Jung, J. W. Kim, and J. M. Lee, “Reinforcement learning for process control: Review and benchmark problems,” *International Journal of Control, Automation and Systems*, vol. 23, pp. 1–40, 2025.